# Relatório Estatístico: inclusão digital nos municípios brasileiros

Modelagem Linear para Aprendizado de Máquina · Global Solution 2026.2 · FIAP · Ciência da Computação · Turma 1CCPZ · Projeto Citizen Assist AI (CitizenTech)


- **Luiz Otávio Brito Freixo** (RM 569977)
- **Ana Beatriz Berbel Marini** (RM 574876)


## Resumo para a tomada de decisão


O Citizen Assist AI orienta cidadãos por um canal digital. Antes de decidir como esse canal deve ser complementado, medimos quem de fato tem internet em casa. Usamos dados reais do IBGE (Censo 2022) dos 5.570 municípios do país.

- No país, 86,35% dos domicílios ocupados têm conexão domiciliar à internet, mas o município típico tem 79,58%. A média por município é menor porque as cidades grandes são mais conectadas: os municípios com mais de 200 mil habitantes têm média de 90,27%, contra 78,65% nos de até 10 mil habitantes.
- 784 municípios (14,1%) têm menos de 70% dos domicílios conectados. Eles reúnem 11.902.854 habitantes (5,9% da população).
- A desigualdade é regional: 42,89% dos municípios do Norte estão abaixo de 70%, contra 2,94% no Sul.
- A alfabetização é o fator que mais acompanha a conectividade (r = 0,622). Um modelo com quatro variáveis explica 50,7% da variação entre municípios, e classifica corretamente 78,9% dos municípios de teste como de alta ou baixa conectividade.

> **Implicação para o projeto.** Onde a alfabetização é menor e as casas são maiores, o canal digital sozinho deixa pessoas de fora. Nesses municípios o assistente deve ser tratado como um complemento de atendimento presencial ou por telefone, e não como substituto. Esta é uma leitura dos resultados, não um resultado estatístico.


## Item 01. Base de dados e justificativa

**Base escolhida:** indicadores reais dos 5.570 municípios brasileiros, obtidos na API de Dados Agregados do IBGE (SIDRA) em 07/11/2026. Nenhum valor foi gerado, simulado ou preenchido por nós. Não há valores ausentes. Arquivo entregue: `base_municipios_ibge.csv`. As URLs exatas de cada consulta estão em `fontes_base_municipios_ibge.txt`.

**Por que esta base é adequada ao tema.** O Citizen Assist AI só alcança quem tem acesso à internet. A base cobre todos os municípios, então os valores de média e desvio padrão são parâmetros da população (não estimativas de amostra). Isso sustenta o uso do desvio padrão populacional nos testes do item 03.

| Variável | Origem (IBGE) | Como foi obtida |
|---|---|---|
| Domicílios com internet (%) | Censo 2022, tabela 9936 | domicílios ocupados com conexão ÷ domicílios ocupados × 100 |
| Alfabetização 15+ (%) | Censo 2022, tabela 9543 | taxa de alfabetização, pessoas de 15 anos ou mais (totais de sexo, cor/raça e idade) |
| PIB per capita (mil R$) | PIB dos Municípios 2022, tabela 5938; população do Censo 2022, tabela 4714 | PIB a preços correntes ÷ população residente |
| Idade mediana (anos) | Censo 2022, tabela 9515 | direto |
| Moradores por domicílio | Censo 2022, tabela 9922 | média de moradores em domicílios particulares permanentes ocupados |

### Medidas descritivas (5.570 municípios; desvio padrão populacional)

| Variável | Média | Desvio padrão | Mínimo | Mediana | Máximo |
|---|---|---|---|---|---|
| Domicílios com internet (%) | 79,58 | 9,10 | 25,52 | 80,99 | 96,90 |
| Alfabetização 15+ (%) | 88,20 | 7,56 | 63,19 | 90,62 | 99,10 |
| PIB per capita (mil R$) | 36,72 | 41,20 | 6,76 | 26,26 | 842,00 |
| Idade mediana (anos) | 35,41 | 4,51 | 15,00 | 36,00 | 53,00 |
| Moradores por domicílio | 2,84 | 0,32 | 2,29 | 2,78 | 5,86 |

### Conectividade por região

| Região | Municípios | Média de domicílios com internet (%) | Municípios abaixo de 70% |
|---|---|---|---|
| Norte | 450 | 72,06 | 42,89% |
| Nordeste | 1.794 | 74,97 | 22,35% |
| Sudeste | 1.668 | 82,01 | 8,27% |
| Centro-Oeste | 467 | 84,03 | 3,64% |
| Sul | 1.191 | 84,24 | 2,94% |

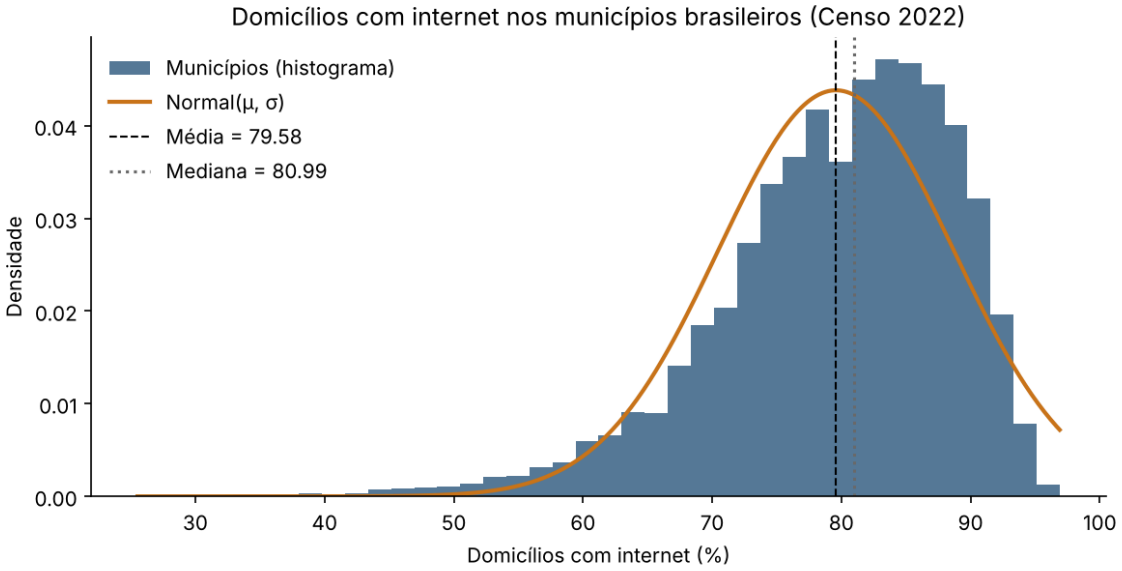
UFs com menor média: AM (59,41%), RR (62,00%), AC (63,01%). UFs com maior média: RO (86,90%), SC (88,20%), DF (94,73%).

## Item 02. Distribuição normal

Variável escolhida: domicílios com internet (%). Pela suposição do enunciado, Y segue uma normal com média μ = 79,58 e desvio padrão σ = 9,10. A mediana dos dados é 80,99.

**a)** P(Y < média) = **50,00%**. Classificação: evento equiprovável (P = 50%). Em qualquer normal, metade da probabilidade fica abaixo da média.

**b)** P(Y > mediana) = 1 − Φ((80,99 − 79,58) ÷ 9,10) = **43,85%**. Classificação: evento menos provável que o seu contrário (P abaixo de 50%). A mediana está acima da média, então sobra menos de metade da probabilidade à direita dela.

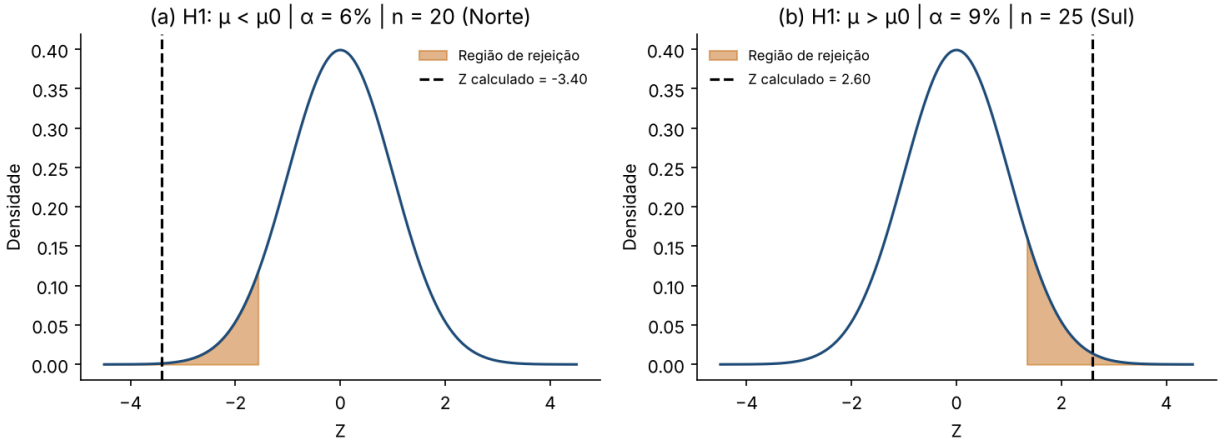



Histograma da variável com a curva normal ajustada. A cauda esquerda do histograma é mais longa que a da curva: a variável tem assimetria de -0,96, então a normal é uma aproximação.

## Item 03. Teste de hipótese para a média

Referência: μ0 = 79,58 (média populacional) e σ = 9,10 (desvio padrão populacional). Estatística: Z = (x̄ − μ0) ÷ (σ ÷ √n). As amostras são aleatórias simples de municípios, com semente fixa (2026). Para que a premissa de cada item seja verdadeira, a amostra (a) vem do Norte, região de menor conectividade, e a amostra (b) vem do Sul, região de maior conectividade. A semente não foi escolhida pelo resultado.

| | Hipóteses | α | n | x̄ | Z calculado | Z crítico | p-valor | Decisão |
|---|---|---|---|---|---|---|---|---|
| a) Norte | H0: μ = μ0 ; H1: μ < μ0 | 6% | 20 | 72,66 | -3,401 | -1,555 | < 0,001 | Rejeita H0 |
| b) Sul | H0: μ = μ0 ; H1: μ > μ0 | 9% | 25 | 84,31 | 2,597 | 1,341 | 0,005 | Rejeita H0 |

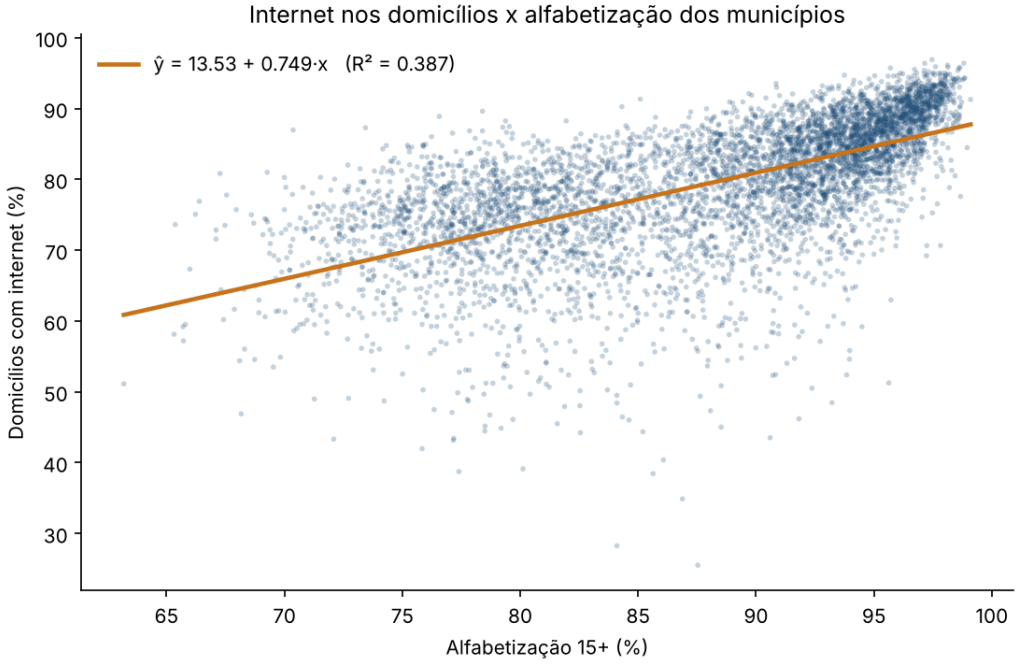



Região de rejeição (laranja) e Z calculado (linha tracejada) em cada teste.

**Interpretação.** (a) Com 6% de significância, há evidência de que a média de conectividade do Norte é menor que a média nacional dos municípios. (b) Com 9% de significância, há evidência de que a média do Sul é maior. Os dois resultados concordam com a tabela por região do item 01.

## Item 04. Análise bivariada: internet x alfabetização

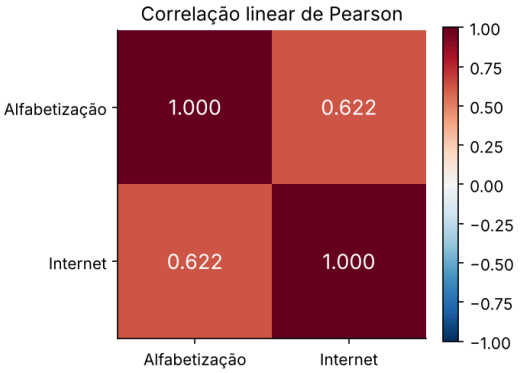
Y = domicílios com internet (%). X = alfabetização de 15 anos ou mais (%). n = 5.570.




a) e d) Gráfico de dispersão com a reta de regressão linear simples.

**a) Interpretação do gráfico.** A nuvem sobe da esquerda para a direita: municípios mais alfabetizados tendem a ter mais domicílios conectados. A dispersão em torno da reta é grande, principalmente entre 75% e 90% de alfabetização, o que indica que há outros fatores além da alfabetização.

**b) Covariância e correlação.** Covariância amostral = **42,81** (positiva: as variáveis variam no mesmo sentido; o valor depende das unidades). Correlação de Pearson r = **0,6220** ($p < 0,001$): correlação linear positiva, entre moderada e forte.




c) Correlação linear de Pearson entre alfabetização e internet.

**c) Interpretação.** O mapa confirma r = 0,622, longe de zero e longe de 1. A relação existe e é clara, mas está longe de ser perfeita.

**d) Equação da reta:**

```
internet (%) = 13,5291 + 0,7489 × alfabetização (%)
```

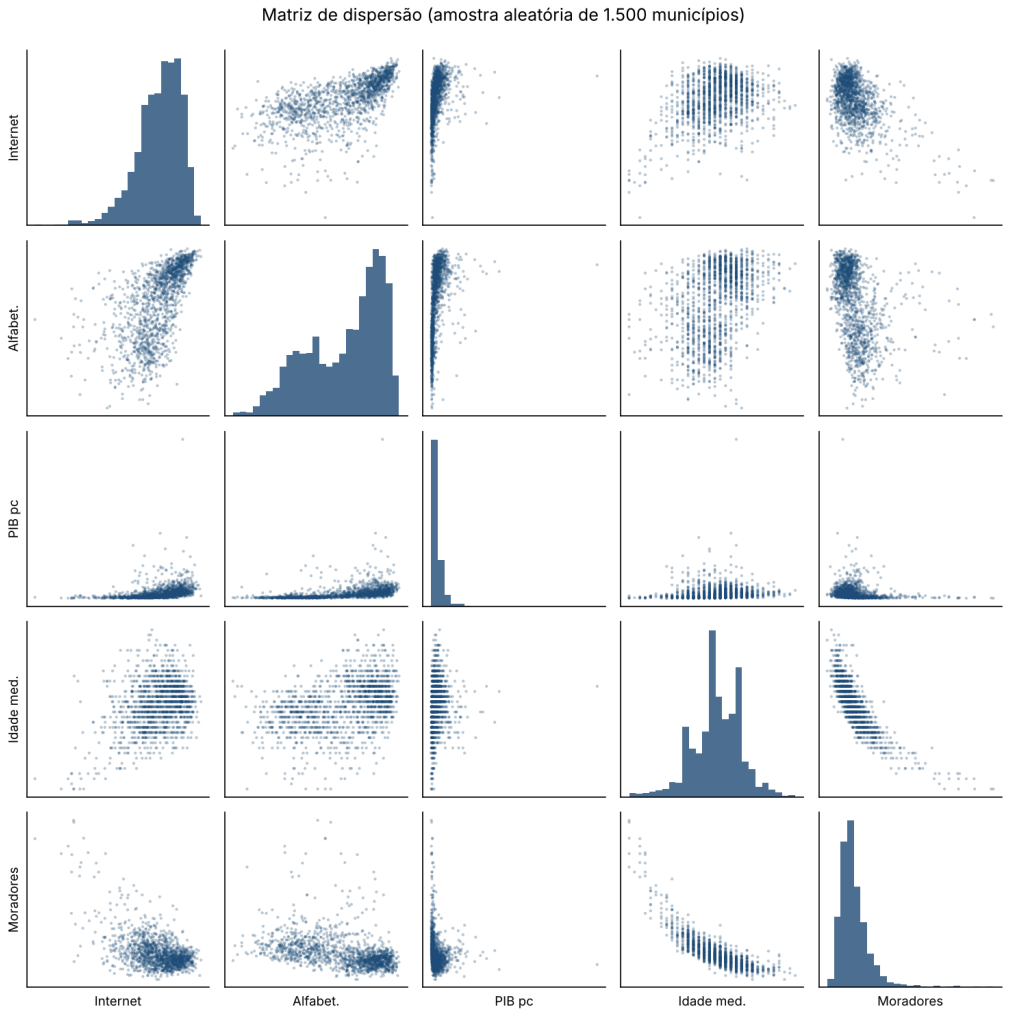
Cada ponto percentual a mais de alfabetização está associado a 0,75 ponto percentual a mais de domicílios com internet. O intercepto não tem leitura prática, pois nenhum município tem alfabetização próxima de zero (mínimo: 63,19%).

**e) Adequação do modelo.** $R^2$ = **0,3869**: a alfabetização explica 38,7% da variação da conectividade. Teste F: F(1; 5568) = **3.513,2**, p < 0,001. Rejeita-se H0 (coeficiente igual a zero): o modelo é estatisticamente significativo. Mas 61,3% da variação fica sem explicação, e o erro padrão dos resíduos é de 7,13 pontos percentuais.

**f) Previsão.** Para um município com 90% de alfabetização: ŷ = 13,5291 + 0,7489 × 90 = **80,93%** de domicílios com internet, com incerteza de cerca de 7,13 pontos percentuais.

## Item 05. Análise multivariada: regressão linear múltipla

Y = domicílios com internet (%). Variáveis explicativas: alfabetização, PIB per capita, idade mediana e moradores por domicílio.




a) Matriz de dispersão (amostra aleatória de 1.500 municípios, apenas para legibilidade; os cálculos usam os 5.570).

**a) Interpretação.** A internet sobe com alfabetização, PIB per capita e idade mediana, e cai com o número de moradores por domicílio. O PIB per capita é muito concentrado em valores baixos, com poucos municípios muito ricos. Idade mediana e moradores por domicílio têm relação linear forte e negativa entre si.

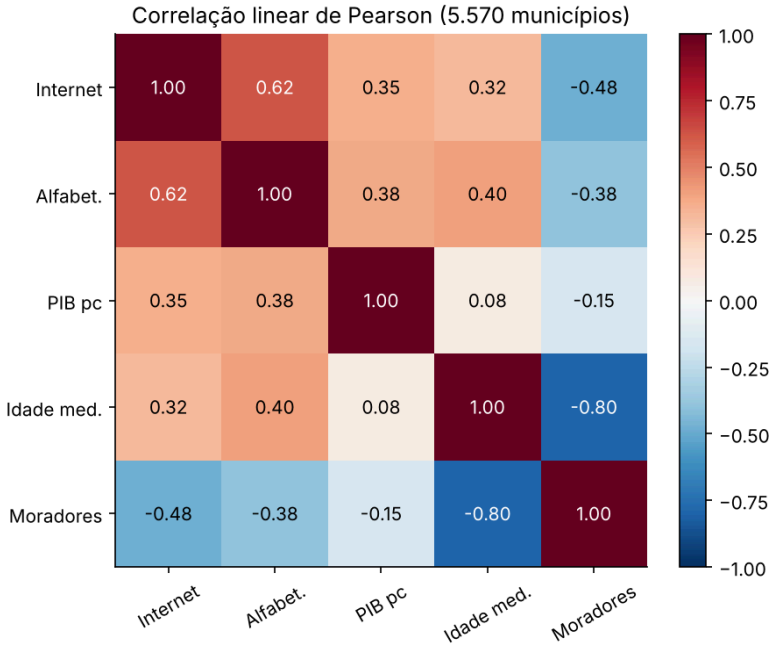
### b) Matriz de covariância

| | Internet | Alfabet. | PIB pc | Idade med. | Moradores |
|---|---|---|---|---|---|
| **Internet** | 82,88 | 42,81 | 131,91 | 12,97 | -1,41 |
| **Alfabet.** | 42,81 | 57,17 | 118,30 | 13,67 | -0,93 |
| **PIB pc** | 131,91 | 118,30 | 1.697,66 | 14,27 | -2,04 |
| **Idade med.** | 12,97 | 13,67 | 14,27 | 20,30 | -1,16 |
| **Moradores** | -1,41 | -0,93 | -2,04 | -1,16 | 0,10 |

### Matriz de correlação de Pearson

| | Internet | Alfabet. | PIB pc | Idade med. | Moradores |
|---|---|---|---|---|---|
| **Internet** | 1,000 | 0,622 | 0,352 | 0,316 | -0,484 |
| **Alfabet.** | 0,622 | 1,000 | 0,380 | 0,402 | -0,385 |
| **PIB pc** | 0,352 | 0,380 | 1,000 | 0,077 | -0,154 |
| **Idade med.** | 0,316 | 0,402 | 0,077 | 1,000 | -0,804 |
| **Moradores** | -0,484 | -0,385 | -0,154 | -0,804 | 1,000 |

Principais resultados: a internet se correlaciona mais com a alfabetização (0,62) e, negativamente, com moradores por domicílio (-0,48). A correlação entre idade mediana e moradores por domicílio é de -0,80: as duas variáveis carregam informação parecida (multicolinearidade).




c) Mapa de correlação linear de Pearson.

**c) Interpretação.** O mapa mostra um bloco forte e negativo entre idade mediana e moradores por domicílio, e correlações positivas moderadas da internet com alfabetização, PIB per capita e idade mediana.

**d) Equação da regressão linear múltipla:**

```
internet (%) = 90,8593 + 0,6122·alfabetização + 0,0224·PIB per capita (mil R$) − 0,6533·idade mediana − 15,1034·moradores por domicílio
```

| Termo | Coeficiente | Estatística t | p-valor |
|---|---|---|---|
| Intercepto | 90,8593 | 36,1 | < 0,001 |
| Alfabetização 15+ (%) | 0,6122 | 45,6 | < 0,001 |
| PIB per capita (mil R$) | 0,0224 | 9,9 | < 0,001 |
| Idade mediana (anos) | -0,6533 | -19,9 | < 0,001 |
| Moradores por domicílio | -15,1034 | -33,2 | < 0,001 |

Cada coeficiente é o efeito de uma variável com as outras mantidas constantes. Alfabetização: +0,61 p.p. por ponto percentual. Moradores por domicílio: -15,1 p.p. por morador a mais. PIB per capita: +0,022 p.p. por mil reais, um efeito pequeno. Atenção: a idade mediana tem sinal negativo no modelo (-0,65), apesar de correlação simples positiva (0,32). Isso acontece porque ela é muito correlacionada com moradores por domicílio; o coeficiente deve ser lido com cautela e não como efeito causal.

**e) Adequação.** $R^2$ = **0,5071**; $R^2$ ajustado = **0,5067**. Teste F: F(4; 5565) = **1.431,2**, p < 0,001. O modelo é significativo e explica cerca de metade da variação, bem mais que o modelo simples (38,7%). Os testes t de todos os coeficientes têm p < 0,001. O erro padrão dos resíduos é de 6,39 p.p.

**f) Previsão com as quatro variáveis.** Para um município hipotético com alfabetização 90%, PIB per capita R$ 25 mil, idade mediana 35 anos e 2,8 moradores por domicílio: ŷ = **81,37%** de domicílios com internet.

## Item 06. Regressão logística binária

Variável resposta: Y = 1 se o município tem alta conectividade (pelo menos 80% dos domicílios com internet), Y = 0 caso contrário. 54,0% dos municípios têm Y = 1. O limite de 80% (8 em cada 10 domicílios) é uma escolha nossa. Os dados foram divididos em treino (4.456) e teste (1.114), 80/20, estratificado, com semente fixa. As mesmas quatro variáveis explicativas do item 05 foram usadas (a própria internet não entra).

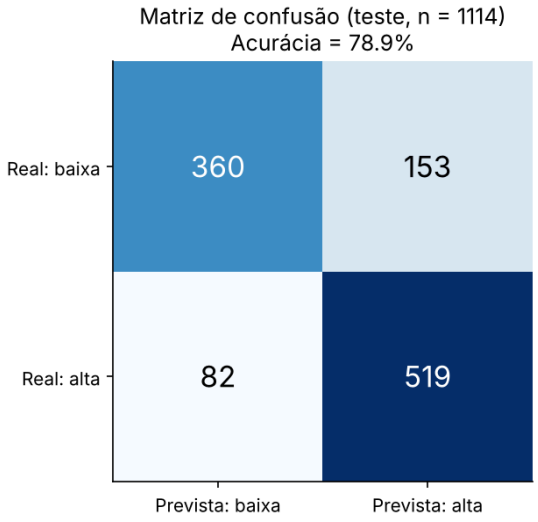
**a) Equação:**

```
ln( p ÷ (1 − p) ) = -5,8924 + 0,2031·alfabetização + 0,0117·PIB per capita −
0,1491·idade mediana − 2,4676·moradores por domicílio
```

Razões de chance ($e^{coeficiente}$): cada ponto percentual de alfabetização multiplica a chance de alta conectividade por 1,225; cada mil reais de PIB per capita, por 1,012; cada ano de idade mediana, por 0,862; cada morador a mais por domicílio, por 0,085. Vale a mesma ressalva sobre a idade mediana do item 05.

**b) Matriz de confusão (conjunto de teste)**

| | **Prevista: baixa** | **Prevista: alta** | **Total real** |
|---|---:|---:|---:|
| **Real: baixa** | VN = 360 | FP = 153 | 513 |
| **Real: alta** | FN = 82 | VP = 519 | 601 |




Matriz de confusão no conjunto de teste.

Acurácia no teste = (360 + 519) ÷ 1114 = **78,9%** (no treino: 79,3%; a proximidade indica que não há sobreajuste). Sensibilidade (altas identificadas) = 86,4%. Especificidade (baixas identificadas) = 70,2%. Precisão das previsões de alta = 77,2%. Para comparação, prever sempre a classe mais frequente acertaria 54,0%. O modelo acerta mais, mas erra mais ao classificar municípios de baixa conectividade como altos (153 casos) do que o contrário (82 casos).

**c) Classificação com quatro variáveis.** Município hipotético com alfabetização 90%, PIB per capita R$ 25 mil, idade mediana 35 anos e 2,8 moradores por domicílio: probabilidade de alta conectividade = **63,4%**. Como é maior que 50%, é classificado como **alta conectividade (Y = 1)**.

## Item 07. Insights e recomendações

- **A média nacional esconde a desigualdade.** 86,35% dos domicílios do país têm internet, mas o município típico tem 79,58%, e 784 municípios ficam abaixo de 70%.
- **O problema é regional.** Norte (72,06%) e Nordeste (74,97%) têm as menores médias, e testes de hipótese confirmam a diferença do Norte para a média nacional (item 03).
- **Educação e composição da casa acompanham a conectividade.** Alfabetização é a variável mais associada (r = 0,62); casas com mais moradores têm menos internet. O PIB per capita tem associação positiva, porém de efeito pequeno quando as demais variáveis são controladas.
- **O modelo é útil para priorizar, não para decidir caso a caso.** Com quatro dados públicos, o modelo logístico acerta 78,9%. Serve para apontar municípios que provavelmente precisam de atendimento presencial ou por telefone junto do assistente digital. Um município isolado pode destoar do modelo.
- **Recomendação para o Citizen Assist AI.** Em municípios de baixa conectividade, manter o assistente em linguagem simples e com orientação para os canais presenciais, e priorizar o atendimento assistido. Esta recomendação é uma interpretação dos resultados.

### Limitações

- Os dados são agregados por município: o resultado vale para municípios, não para pessoas (um município com alta conectividade tem pessoas sem internet).

- Correlação não é causalidade: as regressões descrevem associação.
- A suposição de normalidade vem do enunciado. A variável tem assimetria de -0,96 (cauda longa à esquerda), então as probabilidades do item 02 são aproximações.
- O PIB per capita é muito assimétrico, e a idade mediana é muito correlacionada com moradores por domicílio (multicolinearidade), o que dificulta ler cada coeficiente isoladamente.
- O limite de 80% do item 06 é uma escolha; outro limite mudaria as classes e a acurácia.
- Aurora, a cidade do projeto, é fictícia; este relatório usa só municípios reais e não faz previsão para Aurora.

## Reprodutibilidade

Arquivos entregues: `base_municipios_ibge.csv` (base), `ml_estatistica_cidada.py` (código) e este relatório em PDF. Para reproduzir, na pasta do projeto: `python ml_estatistica_cidada.py` (requer numpy, pandas, scipy, scikit-learn e matplotlib). O código lê a base, refaz todos os cálculos e gráficos, e usa sementes fixas. Fonte dos dados: IBGE, API de Dados Agregados (SIDRA), consultada em 07/11/2026.